

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



**Análisis y anotación de señales bioeléctricas de pacientes con
epilepsia utilizando técnicas de aprendizaje automático
supervisado y no supervisado**

Trabajo de graduación presentado por Camila Lemus Lone para optar
al grado académico de Licenciada en Ingeniería Mecatrónica

Guatemala,

2022

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



**Análisis y anotación de señales bioeléctricas de pacientes con
epilepsia utilizando técnicas de aprendizaje automático
supervisado y no supervisado**

Trabajo de graduación presentado por Camila Lemus Lone para optar
al grado académico de Licenciada en Ingeniería Mecatrónica

Guatemala,

2022

Vo.Bo.:

(f) _____
Dr. Luis Alberto Rivera Estrada

Tribunal Examinador:

(f) _____
Dr. Luis Alberto Rivera Estrada

(f) _____

(f) _____

Fecha de aprobación: Guatemala, de de .

Lista de figuras	VIII
Resumen	IX
Abstract	XI
1. Introducción	1
2. Antecedentes	3
3. Justificación	7
4. Objetivos	9
5. Alcance	11
6. Marco teórico	13
6.1. Epilepsia	13
6.1.1. Síndromes de epilepsia	13
6.1.2. Tipos de crisis epilépticas	14
6.1.3. Diagnóstico	15
6.1.4. Tratamiento	16
6.2. Señales bioeléctricas	17
6.2.1. Electroencefalograma (EEG)	17
6.2.2. Electrocardiograma (ECG)	20
6.2.3. Electromiograma (EMG)	20
6.3. Aprendizaje automático	20
6.3.1. Aprendizaje supervisado	20
6.3.2. Aprendizaje no supervisado	23
6.3.3. Aprendizaje por refuerzo	23
7. Experimentación con aprendizaje automático supervisado	25
7.1. Bases de datos señales EEG	25
7.1.1. Ubonn EEG <i>Dataset</i>	25

7.1.2. Kaggle American Epilepsy Society Seizure Prediction Challenge	26
7.2. Filtrado de la señales	26
7.3. Selección de características	26
7.3.1. Pruebas de rendimiento en la extracción de características	27
7.4. Entrenamiento de clasificadores	27
7.4.1. Redes neuronales (RNA)	27
8. Experimentación con aprendizaje automático no supervisado	33
8.1. Base de Datos - PhysioNet	33
8.2. K-means Clustering	33
9. Conclusiones	37
10.Recomendaciones	39
11.Bibliografía	41
12.Anexos	45
12.1. Repositorio de Github	45
12.2. Matrices de confusión de RNA utilizando características en dominio de la frecuencia para dos clases (Ictal/Sano)	45
12.3. Matrices de confusión de RNA usando características en dominio de la fre- cuencia para dos clases (Interictal/Preictal)	47
12.4. Matrices de confusión de RNA utilizando características individuales en do- minio de la frecuencia para dos clases (Ictal/Sano)	49
12.5. Matrices de confusión de RNA utilizando características individuales en do- minio de la frecuencia para dos clases (Interictal/Preictal)	52

Lista de figuras

1.	Resumen de resultados con clasificador máquina de vectores de soporte (SVM), María Jesús Angulo 2020 [5].	4
2.	Resumen de resultados con clasificador red neuronal artificial (RNA), María Jesús Angulo 2020 [5].	5
3.	Resumen de los resultados de los clasificadores generados: red neuronal (RNA) y máquina de vectores de soporte (SVM), David Vela 2021 [7].	5
4.	Clasificación Operacional de los Tipos de Crisis, Versión Extendida ILAE 2017 [11].	15
5.	Ritmos cerebrales en una señal EEG [22].	18
6.	Arquitectura típica de una red neuronal [30].	22
7.	Definición del “margen” entre clases: el criterio que los SVM intentan optimi- zar [32].	22
8.	Comparación del tiempo de extracción de características por 1 registro.	27
9.	Matriz de confusión Ictal (1) y Sano (2) con RNA, utilizando la razón 1 como característica en dominio de la frecuencia.	28
10.	Matriz de confusión para las clases Ictal (1) y Sano (2) utilizando RNA, utilizando las razones 1, 2 y 3 como características en dominio de la frecuencia.	29
11.	Matriz de confusión para las clases Ictal (1) y Sano (2) utilizando RNA, con el total de características mencionadas anteriormente (6).	29
12.	Matriz de confusión Interictal (1) y Preictal (2) con RNA, utilizando la razón 1 como característica en dominio de la frecuencia.	30
13.	Matriz de confusión para las clases Interictal (1) y Preictal (2) utilizando RNA, utilizando las razones 1, 2 y 3 como características en dominio de la frecuencia.	30
14.	Matriz de confusión para las clases Interictal (1) y Preictal (2) utilizando RNA, con el total de características mencionadas anteriormente (6).	31
15.	Resumen del rendimiento de la RNA para dos clases variando la cantidad de características utilizadas en el dominio de la frecuencia.	32
16.	Resumen del rendimiento de la RNA para dos clasificadores binarios utilizan- do características individuales en dominio de la frecuencia.	32

17.	Experimento k-means con 2 grupos	34
18.	Experimento k-means con 3 grupos	34
19.	Experimento k-means con 4 grupos	34
20.	Experimento k-means con 5 grupos	35
21.	Matriz de confusión Ictal/Sano con RNA, utilizando las razones 1 y 2 como características en dominio de la frecuencia.	46
22.	Matriz de confusión Ictal/Sano con RNA, utilizando las razones 1, 2, 3 y 4 como características en dominio de la frecuencia.	46
23.	Matriz de confusión Ictal/Sano con RNA, utilizando las razones 1, 2, 3, 4 y 5 como características en dominio de la frecuencia.	47
24.	Matriz de confusión Interictal/Preictal con RNA, utilizando las razones 1 y 2 como características en dominio de la frecuencia.	48
25.	Matriz de confusión Interictal/Preictal con RNA, utilizando las razones 1, 2, 3 y 4 como características en dominio de la frecuencia.	48
26.	Matriz de confusión Interictal/Preictal con RNA, utilizando las razones 1, 2, 3, 4 y 5 como características en dominio de la frecuencia.	49
27.	Matriz de confusión Ictal/Sano con RNA, utilizando la razón 2 como característica en dominio de la frecuencia.	50
28.	Matriz de confusión Ictal/Sano con RNA, utilizando la razón 3 como característica en dominio de la frecuencia.	50
29.	Matriz de confusión Ictal/Sano con RNA, utilizando la razón 4 como característica en dominio de la frecuencia.	51
30.	Matriz de confusión Ictal/Sano con RNA, utilizando la razón 5 como característica en dominio de la frecuencia.	51
31.	Matriz de confusión Ictal/Sano con RNA, utilizando la std como característica en dominio de la frecuencia.	52
32.	Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 2 como característica en dominio de la frecuencia.	53
33.	Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 3 como característica en dominio de la frecuencia.	53
34.	Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 4 como característica en dominio de la frecuencia.	54
35.	Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 5 como característica en dominio de la frecuencia.	54
36.	Matriz de confusión Interictal/Preictal con RNA, utilizando la std como característica en dominio de la frecuencia.	55

En Guatemala hay al rededor de 325,000 pacientes con epilepsia, no obstante el acceso a nuevas tecnologías para el estudio de esta enfermedad sigue siendo reducido para algunos neurólogos. Con este trabajo se busca ayudar a los doctores a automatizar el proceso de diagnóstico de epilepsia, mediante una herramienta de *software* en MATLAB, que analice señales bioeléctricas de interés, utilizando técnicas de aprendizaje automático.

Se experimentó con señales electroencefalográficas (EEG) tomadas de la base de datos de la Universidad de Bonn en Alemania y del concurso American Epilepsy Society Seizure Prediction del portal Kaggle. El desarrollo del proyecto consistió en el procesamiento de las señales, la extracción de características en dominio de la frecuencia y posteriormente el entrenamiento y evaluación de dos clasificadores: redes neuronales y máquinas de vectores de soporte. Ambos clasificadores tuvieron un desempeño superior al 99 % para una clasificación binaria de las clases Ictal/Sano y de las clases Interictal/Preictal.

In Guatemala, there are around 325,000 epilepsy patients. However, access to new technologies for the study of this disease remains limited for some neurologists. This work seeks to help doctors with the automation of the epilepsy diagnosis process, with the development of a software tool that analyzes bioelectrical signals of interest using machine learning techniques on MATLAB.

The experimentation carried out in this work, used electroencephalographic (EEG) signals taken from the database of the University of Bonn in Germany and the American Epilepsy Society Seizure Prediction contest by Kaggle. The development of the project consisted of the signal processing, the feature extraction in frequency domain and later, the training and evaluation of two classifiers: neural networks and support vector machines. Both classifiers had a performance greater than 99 % for a binary classification of Ictal/Healthy classes and Interictal/Preictal classes.

La epilepsia es un trastorno neurológico común caracterizado por convulsiones recurrentes e incapacitantes, conocidas como crisis epilépticas. Cada vez es más común el uso de métodos de aprendizaje automático (*Machine Learning* - ML) en aplicaciones clínicas y experimentales para el diagnóstico de la epilepsia y otros trastornos neurológicos y psiquiátricos. Los métodos de ML tienen el potencial de proporcionar un rendimiento fiable y óptimo para el diagnóstico clínico, la predicción y la medicina personalizada mediante el uso de algoritmos matemáticos y enfoques computacionales.

Entre las aplicaciones de ML más comunes para la epilepsia, se encuentra el reconocimiento de patrones de interés en señales EEG. Gracias a esto se ha logrado reducir el tiempo de diagnóstico de esta enfermedad, ya que el método tradicional de análisis y anotaciones manuales hechas por los médicos, suele ser bastante tardado cuando se utilizan registros de varias horas de duración.

El objetivo de este proyecto es mejorar la herramienta de software para el estudio de la epilepsia desarrollada en las fases anteriores para uso médico. Esto mediante la aplicación de nuevas técnicas de aprendizaje automático, analizando diferentes señales bioeléctricas y evaluando los clasificadores. En trabajos previos se utilizaron características en el dominio del tiempo y obtenidas con la transformada Wavelet. En este trabajo se presenta una exploración del reconocimiento de patrones de interés en señales EEG, utilizando características en el dominio de la frecuencia con técnicas de aprendizaje automático supervisado. Asimismo, se muestra el análisis de otras señales bioeléctricas relevantes para el estudio de la epilepsia, utilizando técnicas de aprendizaje automático no supervisado.

En el capítulo 6 de este trabajo, se presentan algunas bases teóricas que se utilizaron para el desarrollo de este proyecto. En los capítulos 7 y 8 se detallan los experimentos realizados, la metodología empleada y los resultados obtenidos. Finalmente, se presentan las conclusiones y recomendaciones para la continuación del estudio.

La epilepsia es una de las afecciones cerebrales graves más comunes y afecta alrededor de 50 millones de personas en todo el mundo [1]. En los últimos años ha aumentado la disponibilidad de aplicaciones clínicas y experimentales de métodos de aprendizaje automático para la epilepsia y otros trastornos neurológicos y psiquiátricos. Mundialmente, se han realizado algunas aplicaciones de aprendizaje automático para la epilepsia, entre las cuales se encuentran, el análisis de neuroimágenes [2], la detección automatizada de convulsiones a partir de electroencefalografía (EEG), videos y datos cinéticos, predicción de la respuesta a la medicación, predicción de los resultados médicos y quirúrgicos, entre otras [3].

En Guatemala se encuentra el Centro de Epilepsia y Neurocirugía Funcional, HUMANA, que es una organización formada por profesionales en Neurociencias que trabajan con pacientes que padecen problemas Neurológicos de difícil control tales como la epilepsia [4]. HUMANA cuenta con el único laboratorio de Video Electro Encefalograma en Guatemala, el cuál permite obtener señales electroencefalográficas (EEG) de pacientes con posibles episodios epilépticos. En una entrevista realizada en 2020 al Dr. Juan Carlos Lara, director de HUMANA, se informó que las anotaciones de las señales EEG se realizan manualmente por profesionales especializados del hospital, lo que implica una gran cantidad de horas de trabajo para resaltar los segmentos de interés y finalmente dar el diagnóstico. El tiempo de esta operación generalmente puede ir desde cuatro horas hasta incluso algunos días, dependiendo de la duración del registro.

En la Universidad del Valle de Guatemala (UVG) se realizó en 2020 la primera iteración de una herramienta software de aprendizaje automático, presentada en el trabajo de graduación titulado *Análisis y Reconocimiento de Patrones de Señales Biomédicas de Pacientes con Epilepsia*, por María Jesús Angulo Tijerino [5]. En este trabajo, se encontró que es posible la detección de crisis epilépticas en señales EEG mediante aprendizaje automático, al realizar la correcta caracterización y división de segmentos. En las Figuras 1 y 2 se muestra un resumen de los resultados de este trabajo de graduación. Paralelo a esto, se creó e implementó una base de datos con señales biomédicas de pacientes de HUMANA, presentada en el trabajo de graduación de María Fernanda Pineda Esmieu, llamado *Diseño e Implemen-*

tación de una Base de Datos de Señales Biomédicas de Pacientes con Epilepsia [6]. La base de datos se enlazó con el sistema de aprendizaje automático mencionado anteriormente, y se comprobó que las características del dominio del tiempo utilizadas en el análisis directo son suficientes para generar una exactitud 95 %.

En 2021, David Alejandro Vela Aguilera presentó la segunda iteración de la herramienta de aprendizaje automático en su trabajo de graduación nombrado *Automatización del Proceso de Anotación de Señales EEG de Pacientes con Epilepsia por Medio de Técnicas de Aprendizaje Automático* [7]. Se realizó ajustes a la interfaz realizada en la fase anterior, la cual fue capaz de emplear algoritmos de aprendizaje automático supervisado para clasificar la señal EEG en una de cuatro clases, obteniendo un promedio de exactitud del 96.7 % en el clasificador con mejor desempeño en tiempo continuo. Se utilizó vectores de soporte con características en tiempo continuo y kernel gaussiano. El resumen de los resultados generados se observa en la Figura 3. Adicional a esto, se agregó una nueva sección a la herramienta iniciada en 2020, la cual se encarga de la generación de anotaciones dentro de un apartado con varias opciones de personalización para la visualización. Cabe resaltar que tanto en la fase de 2020, como en la de 2021, se trabajó, principalmente, con señales EEG en dominio del tiempo, dejando oportunidad para analizar las señales en otro dominio (como el de la frecuencia), y de analizar otro tipo de señales bioeléctricas. Una de las limitaciones que se tuvo en este trabajo, es que principalmente se utilizó técnicas de aprendizaje supervisado, lo que abre espacio para profundizar el análisis de los datos con diferentes técnicas de aprendizaje automático.

En 2022, el trabajo de graduación de Jorge Diego Manrique Sáenz, llamado *Herramienta de Software con una Base de Datos Integrada para el Estudio de la Epilepsia - Fase II* [8], buscó principalmente expandir el modelo relacional de la base de datos para poder almacenar características y clasificadores para el análisis automático de señales EEG. También se adaptó la herramienta para almacenar información confidencial de forma segura y se buscó reducir tiempos en los procesos internos.

Mejores Resultados Clasificador SVM									
Análisis	Caso	Base de Datos	Exactitud	VP	FN	FP	VN	Kernel lineal	Kernel RBF
Directo	1	Ubonn	98.0%	50.0%	0.0%	0.0%	50.0%	x	x
			100.0%	50.0%	0.0%	0.0%	50.0%	x	x
			100.0%	50.0%	0.0%	0.0%	50.0%	x	x
			95.0%	10.0%	1.0%	0.0%	9.0%	x	x
	CHB-MIT		96.3%	38.0%	0.0%	3.0%	41.0%	x	
			100.0%	41.0%	0.0%	0.0%	41.0%	x	
Wavelet	2	Ubonn	100.0%	25.0%	0.0%	0.0%	25.0%	x	
			100.0%	25.0%	0.0%	0.0%	25.0%	x	
			100.0%	25.0%	0.0%	0.0%	25.0%	x	
			100.0%	25.0%	0.0%	0.0%	25.0%	x	

Figura 1: Resumen de resultados con clasificador máquina de vectores de soporte (SVM), María Jesús Angulo 2020 [5].

Mejores Resultados Clasificador ANN							
Análisis	Caso	Base de Datos	Exactitud	VP	FN	FP	VN
Directo	1	Ubonn	99.5%	49.5%	0.0%	0.5%	50.0%
			99.5%	50.0%	0.5%	0.0%	49.5%
		CHB-MIT	97.1%	47.6%	0.5%	2.4%	49.5%
			100.0%	50.0%	0.0%	0.0%	50.0%
Wavelet	2	Ubonn	99.5%	50.0%	0.5%	0.0%	49.5%
		Daubechies 4	99.0%	50.0%	1.0%	0.0%	49.0%
		Daubechies 10	99.5%	50.0%	0.5%	0.0%	49.5%
			99.0%	49.5%	0.5%	0.5%	49.5%
		CHB-MIT					
		Daubechies 4	89.2%	44.9%	5.4%	5.4%	44.4%
		Daubechies 10	81.6%	42.6%	10.8%	7.6%	39.0%

Figura 2: Resumen de resultados con clasificador red neuronal artificial (RNA), María Jesús Angulo 2020 [5].

Características	Tiempo Continuo			Wavelet		
Modelo	RNA	SVM		RNA	SVM	
Kernel	-	Gaussiano	Lineal	-	Gaussiano	Lineal
2 Clases	100.00%	99.80%	100.00%	97.70%	98.70%	97.90%
3 Clases	97.90%	98.90%	97.20%	98.20%	98.30%	97.20%
4 Clases	88.00%	91.30%	88.30%	81.20%	83.30%	77.10%
Promedio	95.30%	96.70%	95.20%	92.40%	93.40%	90.70%
Desv. Estándar	5.23%	3.81%	4.99%	7.90%	7.17%	9.64%

Figura 3: Resumen de los resultados de los clasificadores generados: red neuronal (RNA) y máquina de vectores de soporte (SVM), David Vela 2021 [7].

La epilepsia es uno de los trastornos neurológicos más frecuentes. Según la Organización Mundial de la Salud (OMS) cerca del 80 % de las personas con epilepsia viven en países de ingresos bajos y medianos. Se estima que el 70 % de las personas con epilepsia podría vivir sin convulsiones si se diagnosticaran y trataran adecuadamente [1]. En los últimos años ha aumentado la disponibilidad de aplicaciones clínicas y experimentales de métodos de aprendizaje automático para la epilepsia. No obstante, Guatemala no cuenta con acceso a estas herramientas. Esto implica un gran costo de oportunidad tanto para los doctores como para los pacientes, ya que el análisis de señales consume mucho tiempo y esto atrasa el diagnóstico.

En la UVG se han desarrollado dos fases de una herramienta de *software* para el análisis de señales EEG de pacientes con epilepsia, donde se logró clasificar y realizar anotaciones de estas señales. Sin embargo, la herramienta está limitada para el análisis de un solo tipo de señal bioeléctrica y únicamente los dominios tiempo y tiempo-frecuencia utilizando aprendizaje supervisado.

Con este trabajo se amplió el alcance de esta herramienta de *software* para uso médico incorporando diferentes tipos de análisis. Es importante experimentar con distintas características y técnicas de aprendizaje automático para encontrar las mejores estrategias para el diagnóstico de la epilepsia y hacer una herramienta más eficiente. Se exploró el rendimiento de clasificadores de aprendizaje supervisado utilizando características en el dominio de la frecuencia para señales EEG. Adicionalmente, se evaluaron e incorporaron técnicas de aprendizaje automático no supervisado a la herramienta.

Objetivo General

Mejorar la herramienta de software para el estudio de la epilepsia desarrollada en fases anteriores, incorporando el análisis de distintas señales bioeléctricas, características en el dominio de la frecuencia, y técnicas de aprendizaje automático no supervisado.

Objetivos Específicos

- Evaluar señales bioeléctricas, adicionales a las electroencefalográficas, que sean relevantes en el estudio de la epilepsia, y adaptar la herramienta de software para el análisis de dichas señales.
- Explorar características en el dominio de la frecuencia de las señales bioeléctricas, y evaluar el rendimiento de los algoritmos desarrollados anteriormente usando dichas características.
- Evaluar algoritmos de aprendizaje no supervisado e incorporarlos a la herramienta de software.
- Generar anotaciones relevantes automáticamente y validar los resultados con especialistas de HUMANA.

Con este trabajo de graduación, se busca ampliar las funciones de la herramienta de software para el análisis de la epilepsia desarrollada en 2020 y 2021 en la Universidad del Valle de Guatemala. El alcance de este proyecto incluye la exploración del rendimiento de distintos clasificadores de aprendizaje automático supervisado para señales EEG, utilizando características en el dominio de la frecuencia. Se incluye un análisis individual de las características seleccionadas y de sus diferentes combinaciones. Las clases utilizadas en la experimentación fueron las siguientes: sano, ictal, preictal e interictal. Adicional a esto, se agregó a la herramienta el análisis de señales de electrocardiograma (ECG), las cuales no habían sido utilizadas en las fases anteriores del proyecto. El análisis de las señales ECG, se hizo incorporando técnicas de aprendizaje automático no supervisado.

Entre las limitaciones que se tuvo en el proyecto se encuentran que no fue posible hacer una validación profunda de los resultados mediante asesoría médica y que por falta de tiempo y recursos, no se logró hacer pruebas con los datos de pacientes del hospital HUMANA.

Para la continuación de este proyecto se recomienda ampliar la herramienta incorporando más señales bioeléctricas de interés, por ejemplo, las de electromiograma (EMG). Adicional a esto, sería interesante experimentar con características estadísticas en el dominio de la frecuencia de las señales EEG y posteriormente evaluar su rendimiento con más clasificadores.

6.1. Epilepsia

De acuerdo con la Organización Mundial de la Salud, la epilepsia se define como “una enfermedad cerebral crónica no transmisible que se caracteriza por convulsiones recurrentes, que son episodios breves de movimiento involuntario que pueden involucrar una parte del cuerpo (parcial) o todo el cuerpo (generalizado), y que en ocasiones se acompañan de pérdida de consciencia y control de la función intestinal o vesical”. Este tipo de convulsiones (crisis epilépticas) pueden originarse por diversas causas, que pueden ser estructurales, genéticas, infecciosas, metabólicas, inmunológicas, entre otras. No obstante, en aproximadamente el 50 % de los casos, las causas son desconocidas [1].

Es importante resaltar que no todas las personas que tienen convulsiones, padecen de epilepsia. Una persona puede tener convulsiones debido a causas físicas, por ejemplo enfermedades médicas agudas o traumas que comienza antes de la convulsión o bien pueden relacionarse con alguna sustancia o evento al que su cuerpo responde. En estos casos, las convulsiones se denominan “provocadas” y no se diagnostican como epilepsia. La epilepsia se define por dos o más convulsiones no provocadas [9].

6.1.1. Síndromes de epilepsia

Las características de las convulsiones varían y dependen de en qué parte del cerebro comienza la alteración y cómo se propaga [1]. Para describir los tipos de crisis epilépticas de una persona, los médicos y otros profesionales de la salud a menudo utilizan un grupo de características que generalmente ocurren juntas, llamadas síndromes [9]. Estas características pueden incluir problemas que el paciente presente (síntomas) y resultados que la persona médica encuentre mediante exámenes y pruebas de laboratorio (signos). Entre el conjunto de características que definen a la mayoría de síndromes de epilepsia se encuentran:

- El tipo y la causa de las convulsiones.
- La edad del paciente cuando las convulsiones comienzan.
- La parte del cerebro involucrada.
- Información genética del paciente.
- Patrones específicos encontrados en el electroencefalograma (EEG) durante y entre convulsiones.
- Hallazgos encontrados en imágenes cerebrales, por ejemplo, imágenes por resonancia magnética (MRI) o tomografías computarizadas (CT).
- Las perspectivas de recuperación o empeoramiento.

Cabe mencionar que la epilepsia es un trastorno del espectro, por lo que hay muchos tipos diferentes de convulsiones y de síndromes de epilepsia. Es importante tener conocimiento de que no necesariamente, todas las características mencionadas, describen a todos los síndromes de epilepsia [9].

6.1.2. Tipos de crisis epilépticas

Es de enorme importancia saber distinguir y clasificar los distintos tipos de crisis y encuadrarlos dentro de alguno de los síndromes epilépticos conocidos, ya que, muchas veces de ello dependerá un pronóstico acertado y el éxito del tratamiento [10].

La Liga Internacional contra la Epilepsia (ILAE) presenta una clasificación operacional revisada de los tipos de crisis epilépticas. Esta se observa en la Figura 4. Las principales categorías son: las crisis generalizadas, las crisis focales que también se conocen como crisis parciales y las de inicio desconocido. Entre las subcategorías de estos tipos de crisis se encuentran las motoras y no motoras, y específicamente para las crisis focales, está la subcategoría de sin y con alteración del nivel de conciencia [11].

El que se produzcan un tipo u otro de crisis depende del grupo de neuronas que se activen. Durante las crisis generalizadas hay una activación conjunta de todas las neuronas de la superficie cerebral, mientras que durante las crisis focales solo producen descargas anómalas las neuronas de una zona limitada de la superficie cerebral [12]. Adicional a estos tipos, existen las crisis de inicio desconocido.

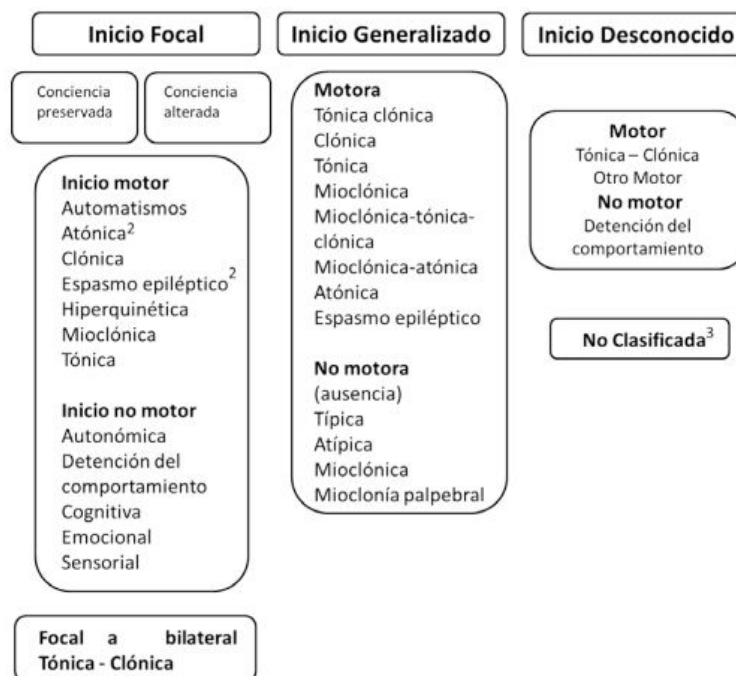


Figura 4: Clasificación Operacional de los Tipos de Crisis, Versión Extendida ILAE 2017 [11].

6.1.3. Diagnóstico

El diagnóstico de epilepsia depende de una historia clínica detallada y precisa hasta en un 90 % [13]. Las pruebas complementarias como la video-electroencefalografía (V-EEG), la tomografía computarizada, las imágenes por resonancia magnética, entre otras, son de ayuda para el estudio y la confirmación ante la sospecha clínica. Esta información no solo permite realizar un diagnóstico adecuado, sino que también permite clasificar de una manera precisa y eficaz las crisis epilépticas, sin dejar de lado la importancia que reviste la semiología al momento de determinar la región cortical que está siendo estimulada y la que finalmente está involucrada en la generación de los síntomas [14]. Para la correcta valoración del paciente con epilepsia, es necesaria la determinación de la causa y la localización de esta actividad eléctricamente aumentada; esto se hace mediante herramientas diagnósticas invasivas y no invasivas.

La video-EEG es una técnica en la que se realiza un electroencefalograma continuo con un equipo digital y una grabación simultánea y sincronizada de la conducta y la actividad motora mediante un circuito cerrado de televisión. Se utiliza en pacientes con sospecha de epilepsia, en desórdenes paroxísticos no epilépticos o para condiciones psiquiátricas, como los ataques de pánico, síndromes conversivos y crisis psicógenas [15].

El monitoreo prolongado permite la identificación de la actividad ictal (durante las crisis) e interictal (fuera de las crisis); además permite la correcta clasificación de las convulsiones y la correlación del comportamiento del paciente con los hallazgos electroencefalográficos. Durante los estudios de V-EEG se utilizan electrodos de superficie no invasivos, pero se pueden incluir también electrodos seminvasivos, tales como los esfenoidales (alambre de

plata recubierto de teflón), colocados mediante anestesia local y que permiten un registro más cercano a los polos de los lóbulos temporales.

Entre otras herramientas que se utilizan para el diagnóstico se encuentran: la magnetoencefalografía (MEG), estudios de neuroimagen, tomografía por emisión de positrones, pruebas neuropsicológicas, en el siguiente artículo se puede encontrar más información al respecto [15].

6.1.4. Tratamiento

Existen diferentes tipos de tratamientos para controlar la epilepsia. El más común es la medicación, en donde los doctores especialistas suelen recetar drogas antiepilépticas (AEDs) que funcionan cambiando el nivel de químicos en el cerebro para controlar y detener los ataques epilépticos [16]. El medicamento es prescrito según el tipo de convulsión, historial médico y edad de la persona. Si el medicamento no funciona, los especialistas pueden recetar combinación de diferentes AEDs. Entre las más comunes se encuentran:

- Valproato de sodio
- Carbamazepina
- Lamotrigina
- Levetiracetam
- Topiramato

La mayoría de las personas que tienen epilepsia responden bien a esta forma de tratamiento, no obstante, algunas personas son resistentes a las AEDs. Lo que significa que su epilepsia no se puede controlar usando las medicaciones prescritas. Entre el 33 % de los adultos y el 20-25 % de los niños con epilepsia no responden a la primera línea de tratamiento, por lo que se deben considerar opciones alternativas [16]. Entre ellas se encuentran:

- Cirugía: Esta opción generalmente funciona mejor para las personas que tienen convulsiones que se originan en una parte específica del cerebro. Se trata de eliminar de forma segura el punto focal, o la parte del cerebro donde comienzan las convulsiones.
- Cambios de Dieta: Algunas dietas pueden ayudar a controlar las convulsiones. Las dietas recomendadas incluyen la dieta Atkins modificada, la dieta cetogénica y la dieta de bajo índice glucémico. Estas dietas deben llevarse a cabo con el apoyo de un especialista.
- Estimulación del Nervio Vago (VNS): Esta terapia trata a las personas con convulsiones focales. Funciona enviando pulsos eléctricos a través del nervio vago que conduce al cerebro.

6.2. Señales bioeléctricas

El análisis de las señales bioeléctricas en el cuerpo humano es de gran importancia para el diagnóstico médico, el monitoreo de signos vitales durante ciertas actividades físicas, en aplicaciones biónicas, entre otras. Estas señales proporcionan información del funcionamiento de los órganos del cuerpo humano, que interpretadas por un especialista se convierten en una poderosa fuente de información del estado de salud de un individuo. Estas señales deben captarse por medios no invasivos para no provocar molestias o daños, así como para simplificar el proceso de adquisición, lo cual se refleja en sistemas más simples y económicos y por lo tanto accesibles a un mayor número de personas [17]. Entre las señales bioeléctricas más populares, se encuentran: las captadas por electroencefalograma, electrocardiograma y electromiograma.

6.2.1. Electroencefalograma (EEG)

El electroencefalograma (EEG) es el registro de la actividad eléctrica del cerebro, obtenida a través de electrodos colocados en el cuero cabelludo. Las señales EEG son empleadas en el estudio de varias enfermedades, pero generan volúmenes de datos que dificultan su procesamiento. El electroencefalograma es particularmente útil para el diagnóstico de la epilepsia, ya que permite detectar el momento en que aparece la anomalía así como su localización, la extensión de la alteración, es decir, si es focal, multifocal, regional o bilateral, su reactividad a estímulos sensoriales (como la luz) y la respuesta a fármacos. Asimismo, se pueden apreciar lentificaciones o aceleraciones de los ritmos cerebrales, y si éstas son pasajeras o permanentes. De igual manera, la morfología que adquieren estos ritmos es útil para identificar el tipo de epilepsia [18].

Ritmos cerebrales

Los patrones más frecuentes en las señales EEG para describir la actividad cerebral son los ritmos. Estos ritmos cerebrales cambian con la edad, con el estado de sueño o vigilia y con la presencia de patología [19]. Como se puede ver en la Figura 5, estos ritmos se pueden asociar a diferentes bandas de frecuencia, siendo éstas:

- Ondas δ (0.5–4 Hz): Son las más lentas pero también las que tienen mayor amplitud. Son características de cuando el individuo está en el sueño profundo y en algunos procesos anormales. Es el ritmo dominante en los lactantes hasta el año de edad y está presente en las etapas 3 y 4 del sueño. [20]. La producción del ritmo Delta, coincide con la regeneración y restauración del Sistema Nervioso Central [21].
- Ondas θ (4–8 Hz): Predominan cuando los sentidos están procesando información interna y el individuo se encuentra desconectado del mundo exterior. Las ondas theta son fuertes durante el enfoque interno como la meditación. El ritmo Theta refleja el estado entre la vigilia y el sueño y se relaciona con la mente subconsciente. Es anormal en adultos despiertos, pero es normal en niños de hasta 13 años. Cuando el ritmo Theta parece funcionar normalmente, media y/o promueve conductas adaptativas complejas como el aprendizaje y la memoria [20].

- Ondas α (8–12 Hz): Predomina cuando el Sistema Nervioso Central se encuentra en reposo, relajado pero despierto y atento. Es el ritmo dominante en un electroencefalograma normal. Está presente durante la mayor parte de la vida, especialmente después de los trece años, cuando domina el ritmo de reposo. El ritmo Alpha es un estado común para el cerebro y ocurre siempre que una persona está alerta, pero no procesa información de forma activa, es decir, cuando la persona está tranquila pero consciente [20].
- Ondas β (12–30 Hz): Predomina durante el periodo de vigilia. Aparece en los estados en que la atención está dirigida a tareas cognitivas externas, al contrario de las ondas Theta, las cuales aparecían durante los estados cognitivos internos. La frecuencia de este ritmo es rápida, está presente cuando estamos atentos y envueltos en la resolución de tareas o problemas cotidianos, también durante la toma de decisiones o cuando estamos concentrados [21]. Es el estado en el que se encuentra la mayor parte del cerebro cuando tenemos los ojos abiertos y escuchamos, pensamos y procesamos la información sobre el mundo que nos rodea. La banda Beta tiene un rango relativamente grande y se ha dividido en bajo, medio y alto.
- Ondas γ (mayores a 30 Hz): Son las ondas más rápidas y se producen en ráfagas cortas. Se relacionan con el proceso de información simultánea en varias áreas del Sistema Nervioso Central. Es el único grupo de frecuencia que se encuentra en todas las partes del cerebro. Se observan ráfagas de ondas Gamma cuando el cerebro está en estado de alta resolución [21].




Figura 5: Ritmos cerebrales en una señal EEG [22].

Características de un registro EEG

Existen múltiples parámetros que nos sirven para identificar o definir un tipo de señal. A estos parámetros se les conoce como características (features) y en el caso de las señales EEG, es común que se clasifiquen en los siguientes grupos:

- Características en dominio del tiempo
- Características en dominio de la frecuencia
- Características no lineales
- Dominio tiempo-escala y tiempo-frecuencia
- Características cepstrales

La selección de éstas características es muy importante al momento de querer analizar y clasificar las señales en algún grupo. Para este trabajo, el enfoque será en las características obtenidas en el dominio de la frecuencia, ya que en las fases anteriores del proyecto [5] y [7] ya se exploró el análisis con señales EEG en dominio del tiempo y tiempo-frecuencia.

Características en el dominio de la frecuencia

La densidad espectral de potencia (PSD) de la señal, que es la base para el cálculo de las características del dominio de la frecuencia, se puede calcular con varios métodos paramétricos y no paramétricos. Los métodos no paramétricos se usan con más frecuencia e incluyen métodos como la transformada de Fourier (generalmente calculada con el algoritmo de transformada rápida de Fourier, FFT), el método de Welch o el método multicono de Thompson [23].

Las características más simples de la señal EEG son características estadísticas, como la media, la mediana, la varianza, la desviación estándar, la asimetría, la curtosis y similares. No obstante, las potencias relativas de ciertas bandas de frecuencia son las características de dominio de frecuencia más utilizadas en todos los campos de análisis de las señales de EEG [23]. Comúnmente, bandas de frecuencia más utilizadas son la Delta, Theta, Alpha, Beta, y Gamma, aunque también existe la banda Sigma (12–14 Hz) que a veces se denomina husos de sueño. Las relaciones entre las bandas de frecuencia (ratios) se utilizan ampliamente como características en el análisis de señales de EEG, por ejemplo:

- θ/α
- β/α
- $(\theta + \alpha)/\beta$
- θ/β
- $(\theta + \alpha)/(\alpha + \beta)$
- γ/δ
- $(\gamma + \beta)/(\delta + \alpha)$

Las medidas de relación de banda se interpretan normalmente como un reflejo de medidas cuantitativas de actividad periódica u oscilatoria. Esto asumiendo que la medida refleja potencias relativas de componentes periódicos distintos que están bien capturados por rangos de frecuencia predefinidos [24].

6.2.2. Electrocardiograma (ECG)

El electrocardiograma o ECG, consiste en la captación de las señales eléctricas originadas por la actividad de biopotenciales en el corazón. La señal captada presenta características diferentes en función del ángulo en que se coloquen los electrodos sobre el cuerpo [25]. Además es útil para detectar problemas cardiacos, como defectos del miocardio, agrandamiento del corazón, defectos congénitos, enfermedades de válvula cardíaca, arritmias, taquicardia o bradicardia, enfermedades de la arteria coronaria, cambios en la cantidad de electrolitos, etc. [26].

El instrumento que se utiliza para adquirir la señal cardiaca se denomina electrocardiógrafo. Los electrocardiógrafos comerciales normalmente adquieren una derivación a la vez. La presentación gráfica del ECG se realiza en una tira de papel con formato cuadrículado estándar, en la mayoría de los casos trazada con una velocidad de 25 milímetros por segundo (mm/s) y con una resolución de amplitud de 10 milímetros por milivoltios (mm/mV) [25].

6.2.3. Electromiograma (EMG)

La electromiografía es un procedimiento de diagnóstico utilizado para evaluar la salud de los músculos y las células nerviosas que los controlan, mejor conocidas como neuronas motoras. Los resultados de la electromiografía pueden revelar una disfunción nerviosa, una disfunción muscular o problemas con la transmisión de señales de nervios a músculos.

En la electromiografía se utilizan electrodos para traducir las señales eléctricas que las neuronas motoras transmiten para contraer los músculos, en gráficos, sonidos o valores numéricos que después interpreta un especialista. [26].

6.3. Aprendizaje automático

El aprendizaje automático (*machine learning*) es una rama de la inteligencia artificial (IA) que, mediante principios estadísticos e informáticos, permite que las máquinas aprendan por sí mismas a realizar una tarea, sin la necesidad de instrucciones explícitas para resolverla. Con el aprendizaje automático, las máquinas desarrollan algoritmos capaces de hacer ajustes y mejorar su rendimiento a través de la inferencia de datos, identificación e interpretación de patrones [3]. Hay más de una manera en que podemos hacer de esta idea una realidad, pero principalmente se reconocen en tres categorías. Estas categorías son aprendizaje supervisado, aprendizaje no supervisado y aprendizaje por refuerzo.

6.3.1. Aprendizaje supervisado

El aprendizaje automático más conocido es el aprendizaje automático supervisado. En este tipo de aprendizaje, se alimenta al algoritmo con iteraciones de datos, lo que permite que los ordenadores interpreten la tarea deseada sin necesidad de programar la tarea de manera explícita. Existen dos tipos principales de aprendizaje supervisado: clasificación y

regresión. La clasificación es el lugar donde se entrena a un algoritmo para clasificar los datos de entrada en variables discretas. Durante el entrenamiento, los algoritmos reciben datos de entrada con una etiqueta de clasificación [27].

La regresión es un método de aprendizaje supervisado en el que se entrena a un algoritmo para predecir una salida a partir de un rango continuo de valores posibles. En la regresión, un algoritmo necesita identificar una relación funcional entre los parámetros de entrada y salida. A diferencia de la clasificación, el valor de salida no es discreto, sino que es una función de los parámetros de entrada. La exactitud de un algoritmo de regresión se calcula en función de la desviación entre la salida precisa y la salida prevista [27].

Entrenamiento del algoritmo

Para entrenar a los algoritmos de ML, es importante separar la data en los siguientes conjuntos:

- Conjunto de datos de entrenamiento: Es la muestra de datos utilizada para ajustar el modelo; en otras palabras es el conjunto de datos real que usamos para entrenar el modelo.
- Conjunto de datos de validación: Corresponde a la muestra de datos utilizada para proporcionar una evaluación imparcial del ajuste de un modelo en el conjunto de datos de entrenamiento mientras se ajustan los hiperparámetros del modelo. La evaluación se vuelve más sesgada a medida que la habilidad en el conjunto de datos de validación se incorpora a la configuración del modelo [28].
- Conjunto de datos de prueba: La muestra de datos utilizada para proporcionar una evaluación imparcial de un ajuste de modelo final en el conjunto de datos de entrenamiento.

Redes neuronales (RNA)

Las redes neuronales (*neural network*) reflejan el comportamiento del cerebro humano, lo que permite que los programas informáticos reconozcan patrones y resuelvan problemas comunes en los campos de la IA, el aprendizaje automático y el aprendizaje profundo [29]. Son una forma de modelar matemáticamente un neurón biológico. Su arquitectura, está inspirada en el cerebro humano y en su estructura ampliamente paralela, cuentan con capacidad de adquirir, almacenar y utilizar conocimiento experimental, generalizando su conocimiento a partir de ejemplos anteriores.

Una red neuronal combina diversas capas de procesamiento y utiliza elementos simples que operan en paralelo. Consta de una capa de entrada, una o varias capas ocultas y una capa de salida. Las capas están interconectadas mediante nodos, o neuronas; cada capa utiliza la salida de la capa anterior como entrada. [30] La siguiente figura muestra de forma visual la arquitectura típica de una red neuronal:




Figura 6: Arquitectura típica de una red neuronal [30].

Con herramientas y funciones para administrar grandes conjuntos de datos, MATLAB ofrece toolboxes especializadas para trabajar con machine learning, tales como la *Deep Learning Toolbox* y la *Parallel Computing Toolbox*.

Máquina de vectores de soporte (SVM)

La máquina de vectores de soporte (*support vector machine* - SVM), es un algoritmo de aprendizaje supervisado que se utiliza en muchos problemas de clasificación y regresión, incluidas aplicaciones médicas de procesamiento de señales, procesamiento del lenguaje natural y reconocimiento de imágenes y voz [31].

El objetivo de este algoritmo es encontrar un hiperplano que separe de la mejor forma posible dos clases diferentes de puntos de datos [32]. Esto implica el hiperplano con el margen más amplio entre las dos clases, representado por los signos $+$ y $-$ en la figura 7. El margen se define como la anchura máxima de la región paralela al hiperplano que no tiene puntos de datos interiores. El algoritmo solo puede encontrar este hiperplano en problemas que permiten separación lineal; en la mayoría de los problemas prácticos, el algoritmo maximiza el margen flexible permitiendo un pequeño número de clasificaciones erróneas.




Figura 7: Definición del “margen” entre clases: el criterio que los SVM intentan optimizar [32].

6.3.2. Aprendizaje no supervisado

Los algoritmos de aprendizaje no supervisado deducen patrones de conjuntos de datos sin tener como referencia resultados previamente etiquetados o conocidos. A diferencia del aprendizaje supervisado, este método no se puede aplicar directamente a un problema de clasificación o regresión de datos, ya que no se tiene conocimiento de cuáles pueden ser los valores de salida. Esto hace que sea imposible entrenar al algoritmo de la forma usual. El aprendizaje no supervisado se utiliza para descubrir la estructura subyacente de los datos [33].

Como los datos que se introducen en los algoritmos de aprendizaje no supervisados no están etiquetados, el algoritmo intenta dar sentido a los datos por sí mismos, mediante la búsqueda de características y patrones. Este método de aprendizaje automático utiliza el agrupamiento (*clustering*), los componentes principales, las redes neuronales y las máquinas de vectores de soporte [27].

K-means Clustering

El objetivo de este algoritmo es agrupar datos, con la cantidad de grupos representados por la variable K. El algoritmo funciona de forma iterativa para asignar cada punto de datos a uno de los K grupos en función de las características proporcionadas. Los puntos de datos se agrupan según la similitud de características entre ellos. Los resultados de este algoritmo de agrupamiento son:

- Los centroides de los grupos K, que se pueden usar para etiquetar nuevos datos.
- Las etiquetas para los datos de entrenamiento (cada punto de datos se asigna a un solo grupo).

Con el K-means clustering, la agrupación permite encontrar y analizar grupos que se han formado orgánicamente, es decir, que los grupos no se asignan antes de ver los datos. Cada centroide de una agrupación, es una colección de valores de características que definen los grupos resultantes. Examinar los pesos de las características del centroide puede ser útil para interpretar cualitativamente la representación de cada grupo.

6.3.3. Aprendizaje por refuerzo

El aprendizaje por refuerzo es un modelo de aprendizaje conductual. Se trata de una forma de optimización basada en datos, en donde la máquina aprende de su propia experiencia, interactuando con el entorno. En el aprendizaje por refuerzo, el algoritmo recibe retroalimentación del análisis de datos, conduciendo al usuario hacia el resultado óptimo. El aprendizaje por refuerzo difiere de otros tipos de aprendizaje supervisado, porque el sistema no está entrenado con el conjunto de datos de ejemplo. Más bien, el sistema aprende a través de la prueba y el error [33].

Experimentación con aprendizaje automático supervisado

Este capítulo contempla el diseño, implementación y evaluación de algoritmos de aprendizaje automático supervisado para el análisis y reconocimiento de patrones en señales EEG. Se detalla la metodología empleada y los resultados obtenidos utilizando dos clasificadores.

7.1. Bases de datos señales EEG

Para explorar y evaluar el rendimiento de los algoritmos desarrollados anteriormente pero con características en el dominio de la frecuencia se requirió de conjuntos de datos etiquetados de señales EEG de pacientes con epilepsia. Se utilizaron los registros de dos bases de datos diferentes, los cuales se encuentran disponibles en el repositorio de Github de este proyecto, disponible en la sección 12.1. A continuación se muestra una descripción de cada base de datos utilizada.

7.1.1. Ubonn EEG *Dataset*

Esta base de datos es propiedad de la Universidad de Bonn, en Alemania y consta de cinco conjuntos de datos denotados con letras desde la A hasta la E correspondientes a señales EEG. Las letras A y B corresponden a registros de pacientes sanos, la C y D corresponden a registros de pacientes con epilepsia pero en un intervalo normal, es decir, libres de crisis epilépticas y la letra E se utiliza para registros ictales, es decir, mientras los pacientes experimentan una crisis epiléptica.

Cada conjunto de datos es de un solo canal y tiene una duración de 23.6 segundos con una frecuencia de muestreo (Fs) de 173.61 Hz. Los registros de esta base de datos utilizados en este trabajo fueron: “SetA_Sano_UBonn.mat” y “SetE_Ictal_UBonn.mat”.

7.1.2. Kaggle American Epilepsy Society Seizure Prediction Challenge

La base de datos utilizada corresponde al concurso “*American Epilepsy Society Seizure Prediction Challenge*”[34] lanzado por Kaggle, el cual consistió en emplear técnicas de aprendizaje automático para predecir episodios de crisis epilépticas. Cada conjunto de datos presentado en el concurso está en formato .mat y corresponden a registros interictales y preictales de un paciente.

Al igual que en la fase anterior del proyecto [7], se utilizó registros comprendidos entre 30 y 40 minutos previo al episodio, ya que estudios [35] determinaron que el tiempo óptimo de predicción se encuentra al rededor de 33.7 minutos. Las señales están compuestas por 15 canales, con una frecuencia de muestreo de 5000 Hz y una duración de 600 segundos. Los registros utilizados de esta base de datos para el presente trabajo fueron: “Interictal_EEG_Data.mat” y “Perictal16_EEG_Data.mat”.

7.2. Filtrado de la señales

En la fase anterior del proyecto [7] se determinó que el filtro idóneo para procesar este tipo de señal era un filtro pasabandas. El cual estaba compuesto por un filtro Butterworth pasa bajas y otro pasa altas, ambos de segundo orden. Las frecuencias de corte para estos filtros fueron de 0.5 Hz y 85 Hz respectivamente.

7.3. Selección de características

En [23] y otros estudios [36][37], se hizo una revisión de múltiples características utilizadas para analizar señales EEG en los diferentes dominios. Se encontró que para el dominio de la frecuencia, las características más utilizadas en todos los campos de análisis de las señales de EEG, son las potencias relativas relacionadas a ciertas bandas de frecuencia. Es por ello que se decidió explorar con las siguientes razones entre bandas como características:

- razón 1 = θ/α
- razón 2 = β/α
- razón 3 = $(\theta + \alpha)/\beta$
- razón 4 = θ/β
- razón 5 = $(\theta + \alpha)/(\alpha + \beta)$
- desviación estándar (std).

Cabe mencionar que características estadísticas como la media, mediana, varianza, desviación estándar, asimetría, curtosis y similares también se utilizan en el dominio de la frecuencia.

7.3.1. Pruebas de rendimiento en la extracción de características

Se experimentó con diferentes combinaciones de características, con el objetivo de explorar cuáles de ellas eran las óptimas para las señales EEG en el dominio de la frecuencia. Las características fueron extraídas de los registros de las clases Sano/Ictal obtenidos de la base de datos de Ubonn y posteriormente de los registros Interictal/Preictal del concurso de Kaggle.

A continuación se muestra un cuadro con la comparación del rendimiento de la computadora al crear los vectores de características para una clase:

Cantidad de características	Promedio de tiempo de extracción de características por registro	
	Ubonn - Sano/Ictal	Kaggle - Interictal/Preictal
1	3.07 min	4.33 min
2	6.13 min	9.08 min
3	8.32 min	15.58 min
4	13.86 min	20.20 min
5	14.92 min	26.86 min
6	15.80 min	26.78 min

Figura 8: Comparación del tiempo de extracción de características por 1 registro.

La diferencia de tiempos entre los diferentes pares de clases (Figura 8), puede deberse a la cantidad de muestras que contenía cada registro. Los datos de Ubonn contienen 409,700 muestras por clase y los datos de Kaggle contienen 3 millones de muestras por clase. Otra posibilidad en el cambio de rendimiento podría ser ocasionada por procesos internos de la computadora. En la Figura 8 también se observa que entre más características se extraigan, el tiempo que toma la creación del vector de características aumenta considerablemente.

7.4. Entrenamiento de clasificadores

Al tener los distintos vectores de características, se procedió a entrenar dos tipos de clasificadores: redes neuronales (RNA) y máquinas de vectores de soporte (SVM). Esto con el fin de evaluar si las características eran las adecuadas para clasificar dos clases y posteriormente comparar el porcentaje de exactitud del clasificador al variar el número de características utilizado.

7.4.1. Redes neuronales (RNA)

Para los algoritmos de redes neuronales, se utilizó una función de gradiente conjugado con 10 capas ocultas y una distribución del 70 % de los datos para el conjunto de entrenamiento, 15 % para el conjunto de validación y 15 % para el conjunto de prueba empleando la

herramienta Neural Net Pattern Recognition de la Deep Learning Toolbox 14.0 de MATLAB R2021a.

Se realizó el entrenamiento para una clasificación binaria, primero de las clases Ictal/Sano y después de las clases Interictal/Preictal. Inicialmente se hicieron pruebas con los vectores de características generados en el apartado 7.3.1, utilizando desde una hasta seis características en dominio de la frecuencia.

Algunas de las matrices de confusión obtenidas, se muestran en las Figuras 9, 10 y 11 para las clases Ictal/Sano y en las Figuras 12, 13 y 14 para las clases Interictal/Preictal.

En la sección 12.2 y 12.3, se pueden encontrar el resto de matrices de confusión para ambos clasificadores, con las distintas pruebas al variar la cantidad de características utilizadas.

Matrices de confusión para los clasificadores binarios con RNA

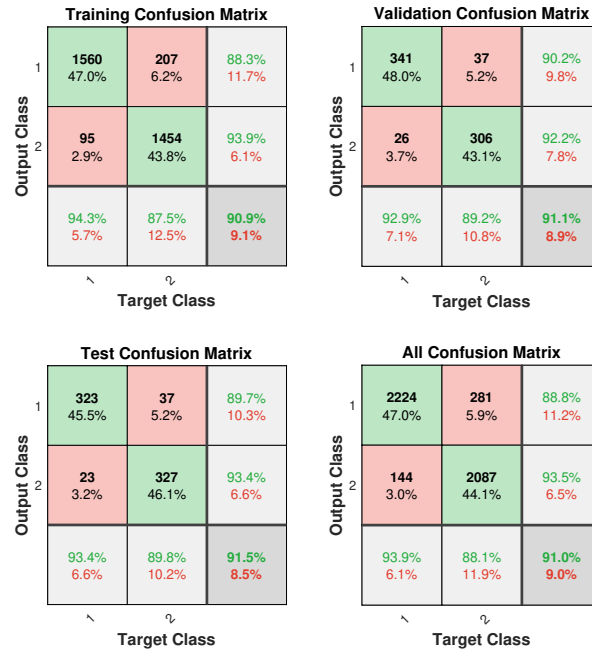


Figura 9: Matriz de confusión Ictal (1) y Sano (2) con RNA, utilizando la razón 1 como característica en dominio de la frecuencia.

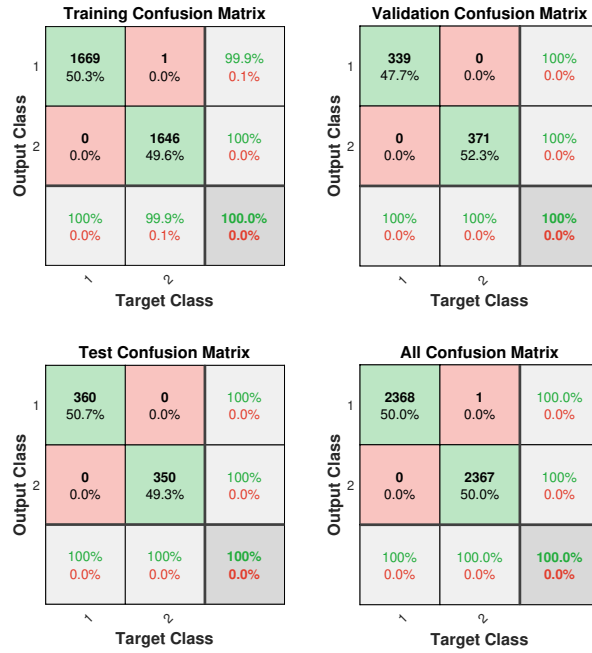


Figura 10: Matriz de confusión para las clases Ictal (1) y Sano (2) utilizando RNA, utilizando las razones 1, 2 y 3 como características en dominio de la frecuencia.

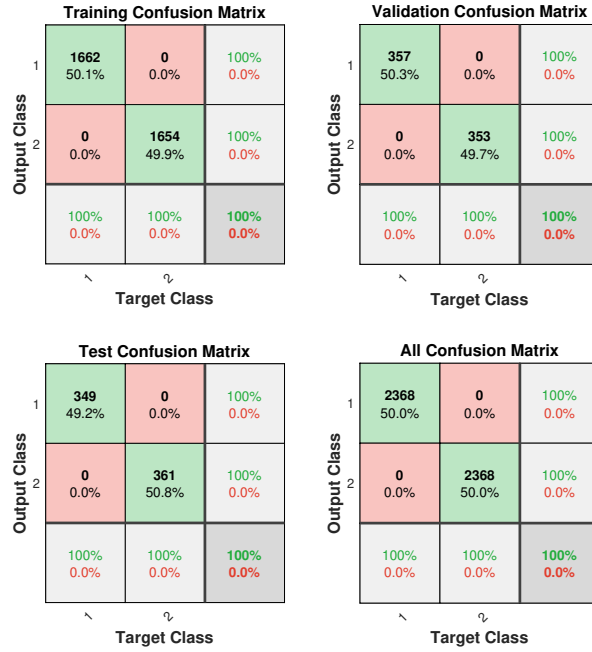


Figura 11: Matriz de confusión para las clases Ictal (1) y Sano (2) utilizando RNA, con el total de características mencionadas anteriormente (6).

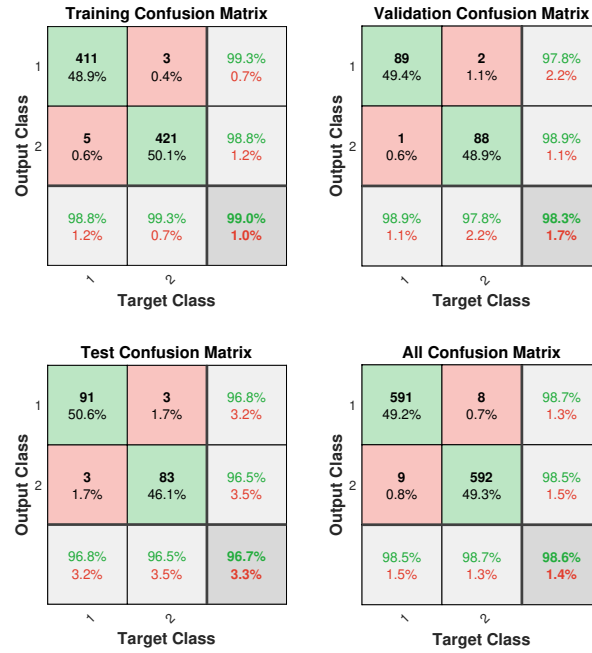


Figura 12: Matriz de confusión Interictal (1) y Preictal (2) con RNA, utilizando la razón 1 como característica en dominio de la frecuencia.

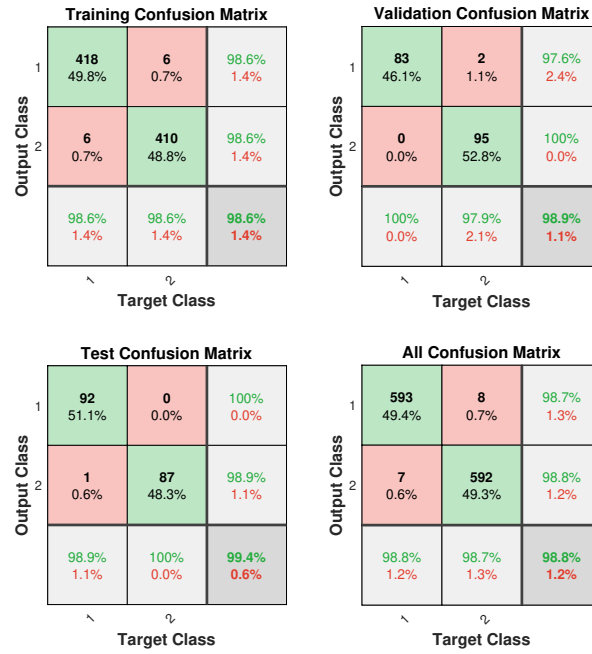


Figura 13: Matriz de confusión para las clases Interictal (1) y Preictal (2) utilizando RNA, utilizando las razones 1, 2 y 3 como características en dominio de la frecuencia.

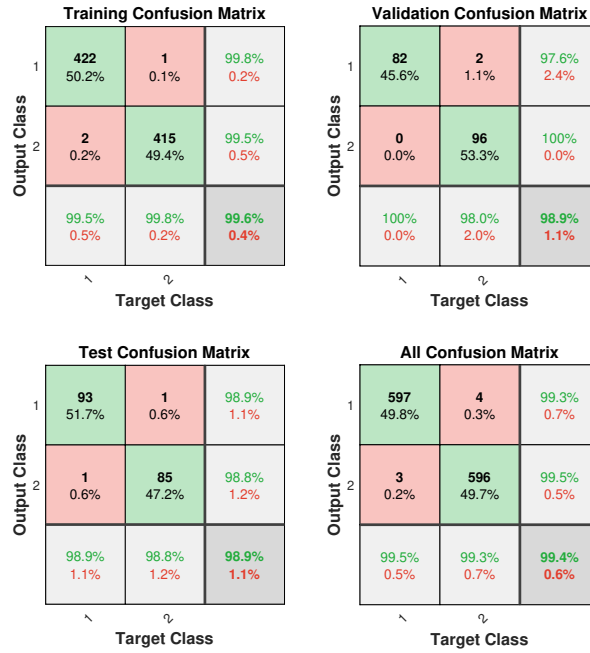


Figura 14: Matriz de confusión para las clases Interictal (1) y Preictal (2) utilizando RNA, con el total de características mencionadas anteriormente (6).

Al tener clasificaciones satisfactorias, como se observa en la Figura 15, utilizando desde una hasta seis características, se decidió hacer otro experimento. Este consistió en probar el rendimiento de la computadora al extraer cada característica individualmente y posterior a eso evaluar la exactitud de la red neuronal. Todo esto se realizó con el objetivo de determinar si las características individuales eran lo suficientemente buenas para generar resultados satisfactorios a un menor costo computacional, e identificar las más precisas según el tipo de clases. En La Figura 16, se observa un resumen del rendimiento y la exactitud del clasificador para cada tipo de característica. En la sección 12.4 y 12.5 de Anexos se encuentra el resto de matrices de confusión del clasificador por cada característica individualmente.

Resumen de los resultados del clasificador

Cantidad de características	Características utilizadas (razones)	Exactitud RNA	
		Ubonn - Sano/Ictal	Kaggle - Interictal/Preictal
1	1	91.55%	90.50%
2	1, 2	100%	98.90%
3	1, 2, 3	99.99%	98.80%
4	1, 2, 3, 4	99.99%	98.80%
5	1, 2, 3, 4, 5	99.99%	98.80%
6	1, 2, 3, 4, 5, std	100%	99.40%

Figura 15: Resumen del rendimiento de la RNA para dos clases variando la cantidad de características utilizadas en el dominio de la frecuencia.

Como se observa en la Figura 15, los resultados de clasificación para los dos pares de clases fueron muy similares al utilizar dos o más características. El nivel de exactitud para el clasificador Ictal/Sano, se encuentra sobre el 99.99 % en estos casos y el clasificador Interictal/Preictal tuvo una exactitud superior al 98.80 % de igual manera.

De los resultados obtenidos, se observa que al entrenar el clasificador utilizando únicamente dos características en dominio de la frecuencia, se obtienen resultados muy similares que al utilizar tres o más. Entonces, se puede decir que, computacionalmente hablando, es recomendable utilizar un menor número de características en el dominio de la frecuencia para clasificar las dos clases, ya que se invierte menos tiempo y tenemos una exactitud bastante certera en la clasificación.

Extracción de características en dominio de la frecuencia				
Característica	Ubonn - Sano/Ictal		Kaggle - Interictal/Preictal	
	Porcentaje de rendimiento RNA	Tiempo	Porcentaje de rendimiento RNA	Tiempo
razón 1	91.00%	3.10 min	98.60%	4.52 min
razón 2	91.10%	3.08 min	84.20%	4.46 min
razón 3	77.00%	4.60 min	98.50%	6.76 min
razón 4	99.70%	2.88 min	96.10%	4.50 min
razón 5	90.90%	4.60 min	98.30%	6.16 min
std	99.60%	11.00 s	67.40%	9.73 s

Figura 16: Resumen del rendimiento de la RNA para dos clasificadores binarios utilizando características individuales en dominio de la frecuencia.

Al momento de experimentar con las características individuales Figura 16, también se obtuvo resultados satisfactorios. El porcentaje de exactitud en el clasificador Ictal/Sano fue superior al 90 % para cinco de las seis características seleccionadas, (a excepción de la razón 3). Y en el clasificador Interictal/Preictal la exactitud fue superior al 96 % para la mayoría de las características.

Experimentación con aprendizaje automático no supervisado

Este capítulo contempla el diseño, implementación y evaluación de algoritmos de aprendizaje automático no supervisado para el análisis y reconocimiento de patrones en señales ECG. Se detalla la metodología empleada y los resultados obtenidos utilizando el algoritmo k-means clustering.

8.1. Base de Datos - PhysioNet

La base de datos utilizada se llama “*Post-Ictal Heart Rate Oscillations in Partial Epilepsy*” disponible en el portal PhysioNet [38]. Contiene registros de ECG anotados los cuales corresponden a oscilaciones de la frecuencia cardíaca postictal en un grupo heterogéneo de pacientes con epilepsia parcial.

La data utilizada, se caracteriza por la aparición de oscilaciones de frecuencia cardíaca de baja frecuencia transitorias de entre 0,01 Hz a 0,1 Hz inmediatamente después de cinco de las once convulsiones registradas en cinco pacientes.

8.2. K-means Clustering

Para utilizar el algoritmo K-means se especificó el número de grupos K, que se deseaba encontrar. Se experimentó variando la cantidad de grupos, siendo estos 2, 3, 4 y 5.

Primero se eligió la localización de los centroides de los K grupos aleatoriamente. Posteriormente se asignó un dato al centroide mas cercano para finalmente actualizar la posición del centroide según la media aritmética de las posiciones de los datos asignados al grupo.

Experimentos




Figura 17: Experimento k-means con 2 grupos




Figura 18: Experimento k-means con 3 grupos




Figura 19: Experimento k-means con 4 grupos




Figura 20: Experimento k-means con 5 grupos

Conclusiones

- Las relaciones entre bandas de frecuencia, son características funcionales para la clasificación binaria, dado que se obtuvo un porcentaje de rendimiento superior al 99 % utilizando redes neuronales con dos o más características para las clases Ictal/Sano y superior a un 98.80 % para las clases Interictal/Preictal.
- Es conveniente que el vector de características se genere combinando la razón 1 (θ/α) y la razón 2 (β/α), dado que los clasificadores tienen un rendimiento igual o mayor a 98.90 % en un menor tiempo.
- La extracción de características en dominio de la frecuencia no es muy eficiente, dado que en promedio tarda aproximadamente 3 minutos por registro individual para procesar 409,700 muestras y 4.33 minutos para procesar 3 millones de muestras.

Recomendaciones

- Para la continuación de este proyecto, se recomienda ampliar la herramienta de incorporando más señales bioeléctricas de interés, por ejemplo, las de electromiograma (EMG).
- Se recomienda seguir experimentando el rendimiento de los clasificadores con diferentes técnicas de aprendizaje automático no supervisado, tanto para señales EEG, ECG y otras señales bioeléctricas de interés en el estudio de la epilepsia.
- Para proyectos futuros, podría mejorarse el proceso de selección de características de las señales mediante asesoría médica. Adicional a eso se recomienda validar constantemente con los especialistas, las predicciones de los clasificadores.

- [1] O. Organización Mundial de la Salud, *Epilepsia*, Último acceso 30 Abril 2022, 2022. dirección: <https://www.who.int/es/news-room/fact-sheets/detail/epilepsy>.
- [2] D. Sone e I. Beheshti, “Clinical Application of Machine Learning Models for Brain Imaging in Epilepsy: A Review,” *Frontiers in Neuroscience*, vol. 15, 2021.
- [3] B. Abbasi y D. M. Goldenholz, “Machine learning applications in epilepsy,” *Epilepsia*, vol. 60, n.º 10, págs. 2037-2047, 2019.
- [4] H. Centro de Epilepsia y Neurocirugía Funcional, *HUMANA*, Último acceso 25 Abril 2022, 2022. dirección: <https://humanagt.org/>.
- [5] M. J. A. Tijerino, “Análisis y Reconocimiento de Patrones de Señales Biomédicas de Pacientes con Epilepsia,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2020.
- [6] M. F. P. Esmieu, “Diseño e Implementación de una Base de Datos de Señales Biomédicas de Pacientes con Epilepsia,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2020.
- [7] D. A. V. Aguilera, “Automatización del Proceso de Anotación de Señales EEG de Pacientes con Epilepsia por Medio de Técnicas de Aprendizaje Automático,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2021.
- [8] J. D. M. Sáenz, “Herramienta de Software con una Base de Datos Integrada para el Estudio de la Epilepsia - Fase II,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2022.
- [9] E. C. Foundation, *Epilepsy*, Último acceso 08 Mayo 2022, 2022. dirección: <https://www.epilepsy.com/what-is-epilepsy>.
- [10] C. V. Torres, “Epilepsia,” *Medicine - Programa de Formación Médica Continuada Acreditado*, vol. 11, n.º 73, págs. 4364-4373, 2015.
- [11] R. S, “Clasificación operacional de los tipos de crisis por la Liga Internacional contra la Epilepsia: Documento - Posición de la Comisión para Clasificación y Terminología de la ILAE,” *Epilepsia*, vol. 58, n.º 4, págs. 522-530, 2017.

- [12] A. A. de Epilepsia, *Diferentes tipos de crisis epilépticas*, Último acceso 09 Mayo 2022, 2022. dirección: <https://www.apicepilepsia.org/que-es-la-epilepsia/diferentes-tipos-de-crisis-epilepticas/>.
- [13] R. Fisher, C. Acevedo, A. Arzimanoglou y col., "ILAE Official Report: A practical clinical definition of epilepsy.," *Epilepsia*, vol. 55, n.º 4, 2014.
- [14] E. Palacios y C. Clavijo-Prado, "Semiología de la crisis epiléptica: un reto clínico.," *Repertorio de Medicina y Cirugía*, vol. 25, n.º 4, 2016.
- [15] P. S. Bialik y M. Á. C. Corona, "Avances en el manejo de la epilepsia.," *Neurología, Neurocirugía y Psiquiatría*, vol. 45, n.º 1, 2017.
- [16] N. H. Service, *Treatment - Epilepsy*, Último acceso 08 Mayo 2022, 2020. dirección: <https://www.nhs.uk/conditions/epilepsy/treatment/>.
- [17] J. Varela-Benítez, "Electrodo capacitivo de alta sensibilidad para la detección de biopotenciales eléctricos," *Revista mexicana de ingeniería biomédica*, vol. 2, n.º 36, págs. 14-23, 2015.
- [18] S. Brailowsky, *Epilepsia*, 1.^a ed. Fondo de Cultura Económica, 2014.
- [19] C. Bazán, M. Blanco, J. Cárdenas y F. Cruz, "Compresión de señales electroencefalográficas epilépticas y normales," *Ingeniería Electrónica, Automática y Comunicaciones*, vol. 33, n.º 1, págs. 25-32, 2012.
- [20] N. Barcelona, *¿Qué son las ondas Cerebrales?* Último acceso 18 septiembre 2022, 2022. dirección: <https://www.neurofeedback.cat/que-son-las-ondas-cerebrales/>.
- [21] N. Associates, *Brain Wave Frequencies*, Último acceso 18 septiembre 2022, 2022. dirección: <https://nhahealth.com/brainwaves-the-language/#:~:text=The%20raw%20EEG%20has%20usually%20for%20%E2%80%9Cactive%E2%80%9D%20intelligence..>
- [22] R. Vallat, *Compute the average bandpower of an EEG signal*, Último acceso 18 septiembre 2022, 2018. dirección: <https://raphaelvallat.com/bandpower.html>.
- [23] I. Stancin, M. Cifrek y A. Jovic., "A Review of EEG Signal Features and their Application in Driver Drowsiness Detection Systems.," *Sensors (Basel)*, vol. 21, n.º 11, 2021.
- [24] T. Donoghue, J. Dominguez y B. Voytek., "Electrophysiological Frequency Band Ratio Measures Conflate Periodic and Aperiodic Neural Activity.," *eNeuro*, vol. 7, n.º 6, 2020.
- [25] N. Dugarte, "Técnicas de procesamiento de la señal ECGAR aplicadas en el prototipo DIGICARDIAC," *Revista del Instituto Nacional de Higiene Rafael Rangel*, vol. 46, n.º 1-2, 2015.
- [26] L. A. Osorio, "Acondicionamiento de Señales Bioeléctricas," Tesis de licenciatura, Universidad Tecnológica de Pereira, 2007.
- [27] TIBCO, *¿Qué es el aprendizaje supervisado?* Último acceso 08 Mayo 2022, 2022. dirección: <https://www.tibco.com/es/reference-center/what-is-supervised-learning#:~:text=El%5C%20aprendizaje%5C%20supervisado%5C%20es%5C%20una,de%5C%20manera%5C%20expl%5C%C3%5CADcita%5C%20d%5C%C3%5CB3nde%5C%20buscar.>

- [28] T. Shah, *About Train, Validation and Test Sets in Machine Learning*, Último acceso 18 septiembre 2022, 2017. dirección: <https://towardsdatascience.com/train-validation-and-test-sets-72cb40cba9e7>.
- [29] I. C. Education, *Neural Networks*, Último acceso 18 septiembre 2022, 2022. dirección: <https://www.ibm.com/cloud/learn/neural-networks>.
- [30] MathWorks, *¿Qué es una red neuronal?* Último acceso 20 septiembre 2022, 2022. dirección: <https://la.mathworks.com/discovery/neural-network.html>.
- [31] IBM, *Funcionamiento de SVM*, Último acceso 20 septiembre 2022, 2021. dirección: <https://www.ibm.com/docs/es/spss-modeler/saas?topic=models-how-svm-works>.
- [32] MathWorks, *Support Vector Machine (SVM)*, Último acceso 20 septiembre 2022, 2022. dirección: <https://la.mathworks.com/discovery/support-vector-machine.html>.
- [33] L. Gonzalez, *Aprendizaje no Supervisado*, Último acceso 08 May 2022, 2020. dirección: <https://aprendeia.com/aprendizaje-no-supervisado-machine-learning/>.
- [34] Kaggle, *American Epilepsy Society Seizure Prediction Challenge*, Último acceso 18 septiembre 2022, 2015. dirección: <https://www.kaggle.com/c/seizure-prediction/data>.
- [35] I. B. Slimen, L. Boubchir y H. Seddik, "Epileptic seizure prediction based on EEG spikes detection of ictal-preictal states.," *J Biomed Res*, vol. 34, n.º 3, 2020.
- [36] H. J. Eoh, M. K. Chung y S.-H. Kim, "Electroencephalographic study of drowsiness in simulated driving with sleep deprivation.," *International Journal of Industrial Ergonomics*, vol. 35, n.º 4, 2005.
- [37] O. Dressler, G. Schneider, G. Stockmanns y E. F. Kochs, "Awareness and the EEG power spectrum: analysis of frequencies," *BJA: British Journal of Anaesthesia*, vol. 93, n.º 6, págs. 806-809, 2004.
- [38] PhysioNet, *Post-Ictal Heart Rate Oscillations in Partial Epilepsy*, Último acceso 25 septiembre 2022, 1999. dirección: <https://physionet.org/content/szdb/1.0.0/>.

12.1. Repositorio de Github

En el siguiente enlace se encuentra el repositorio de Github que contiene los códigos y los sets de datos utilizados en este trabajo de graduación:

<https://github.com/camilalemus/Estudio-Epilepsia-2022>

12.2. Matrices de confusión de RNA utilizando características en dominio de la frecuencia para dos clases (Ictal/Sano)

La etiqueta 1 corresponde a la clase ictal y la etiqueta 2 corresponde a la clase sano.

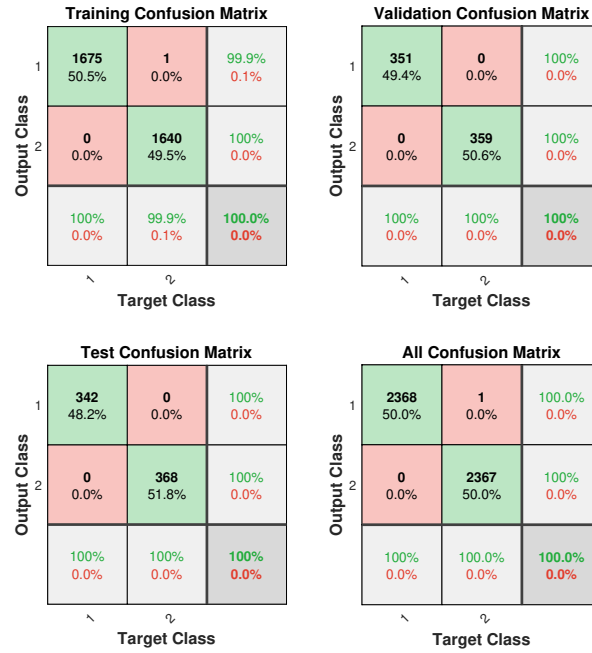


Figura 21: Matriz de confusión Ictal/Sano con RNA, utilizando las razones 1 y 2 como características en dominio de la frecuencia.

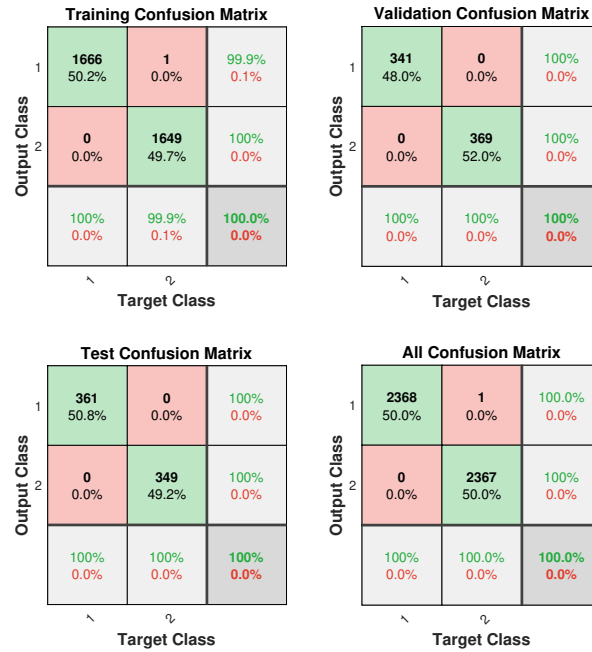


Figura 22: Matriz de confusión Ictal/Sano con RNA, utilizando las razones 1, 2, 3 y 4 como características en dominio de la frecuencia.

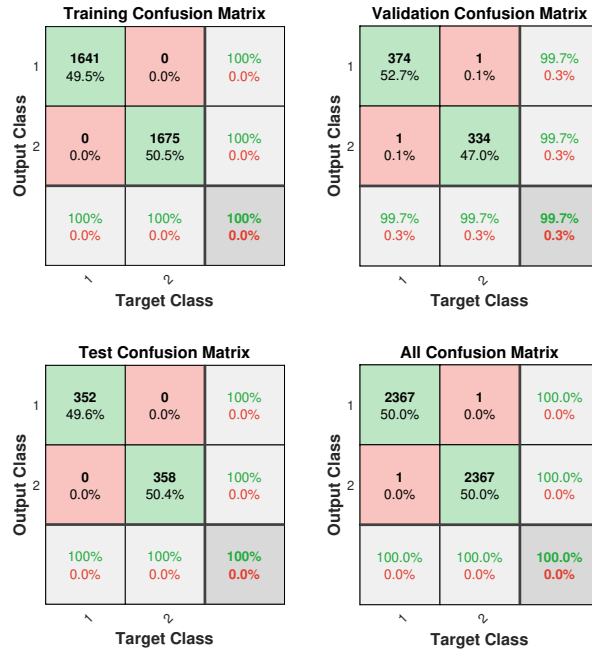


Figura 23: Matriz de confusión Ictal/Sano con RNA, utilizando las razones 1, 2, 3, 4 y 5 como características en dominio de la frecuencia.

12.3. Matrices de confusión de RNA usando características en dominio de la frecuencia para dos clases (Interictal/Preictal)

La etiqueta 1 corresponde a la clase interictal y la etiqueta 2 a la clase preictal.

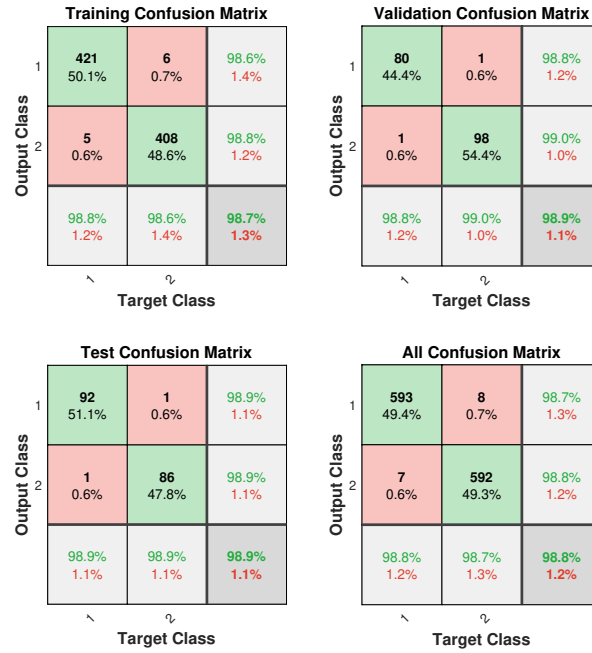


Figura 24: Matriz de confusión Interictal/Preictal con RNA, utilizando las razones 1 y 2 como características en dominio de la frecuencia.

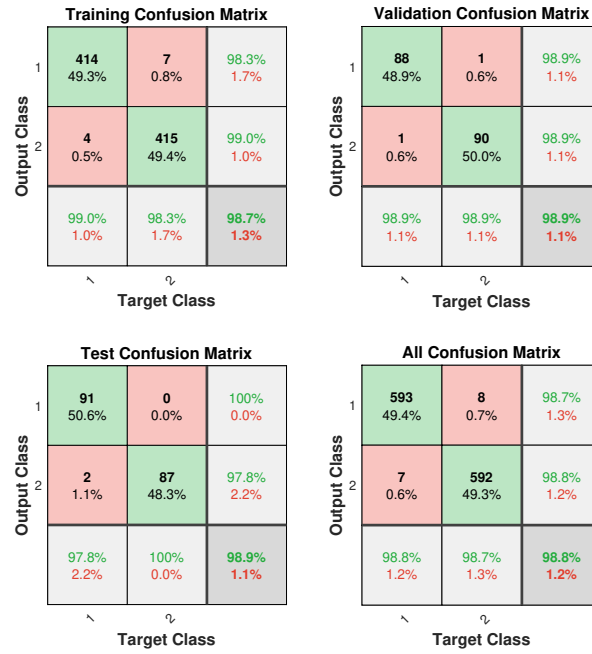


Figura 25: Matriz de confusión Interictal/Preictal con RNA, utilizando las razones 1, 2, 3 y 4 como características en dominio de la frecuencia.

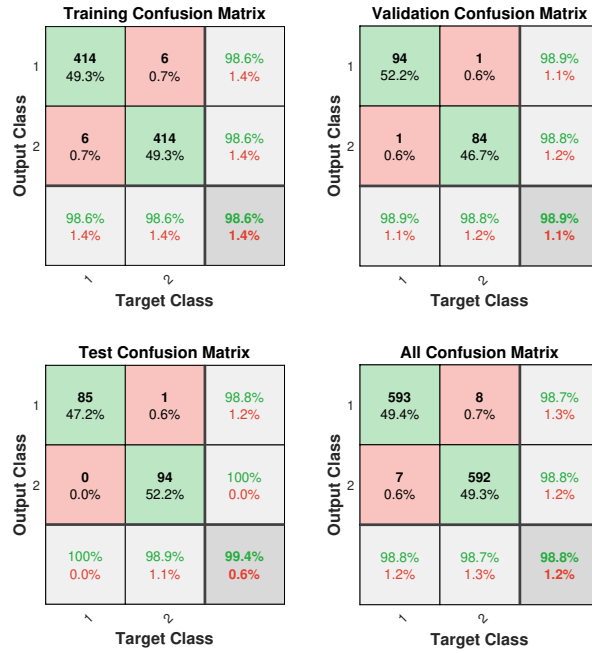


Figura 26: Matriz de confusión Interictal/Preictal con RNA, utilizando las razones 1, 2, 3, 4 y 5 como características en dominio de la frecuencia.

12.4. Matrices de confusión de RNA utilizando características individuales en dominio de la frecuencia para dos clases (Ictal/Sano)

La etiqueta 1 corresponde a la clase ictal y la etiqueta 2 corresponde a la clase sano.

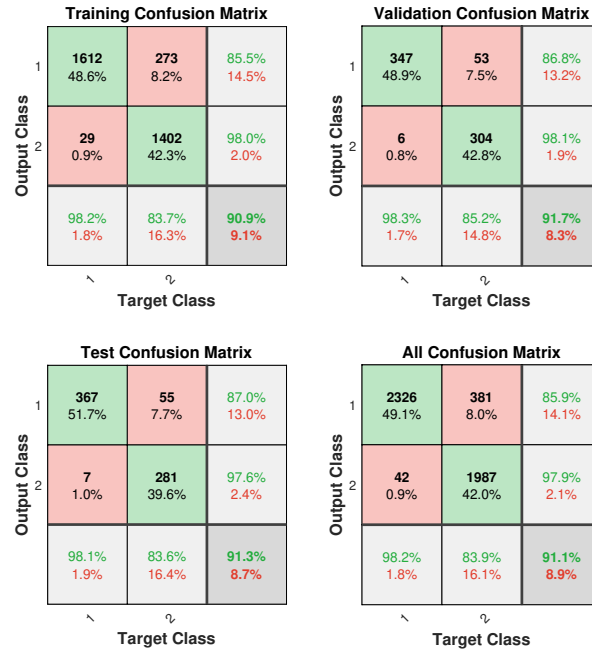


Figura 27: Matriz de confusión Ictal/Sano con RNA, utilizando la razón 2 como característica en dominio de la frecuencia.

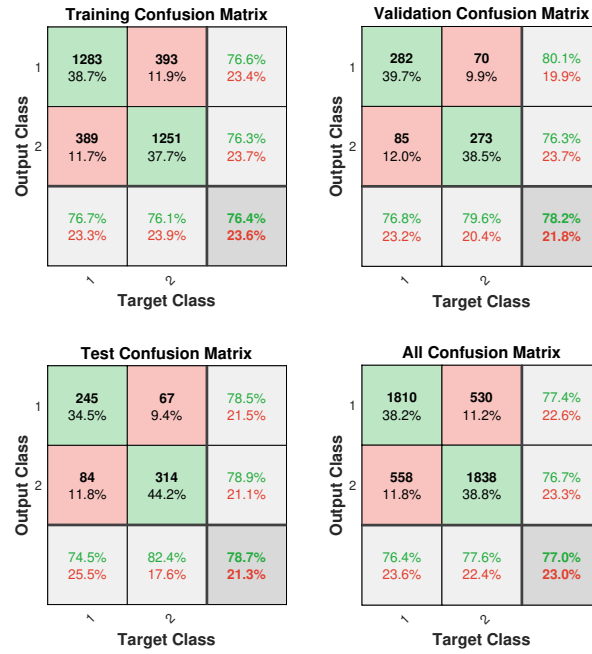


Figura 28: Matriz de confusión Ictal/Sano con RNA, utilizando la razón 3 como característica en dominio de la frecuencia.

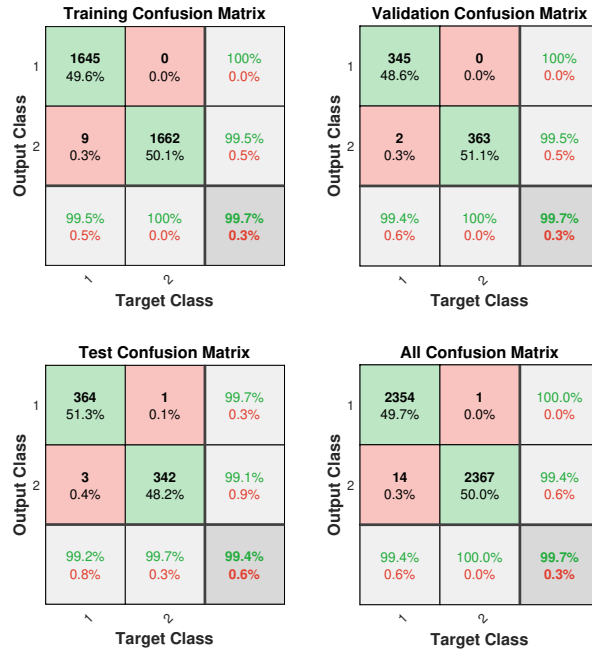


Figura 29: Matriz de confusión Ictal/Sano con RNA, utilizando la razón 4 como característica en dominio de la frecuencia.

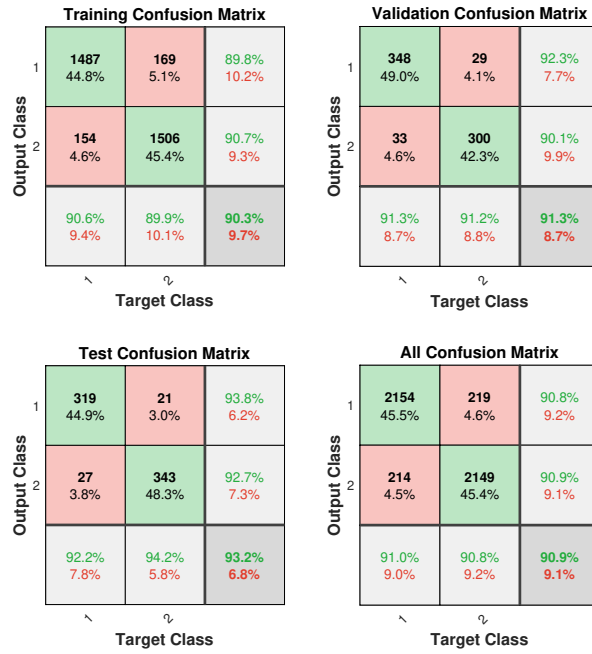


Figura 30: Matriz de confusión Ictal/Sano con RNA, utilizando la razón 5 como característica en dominio de la frecuencia.

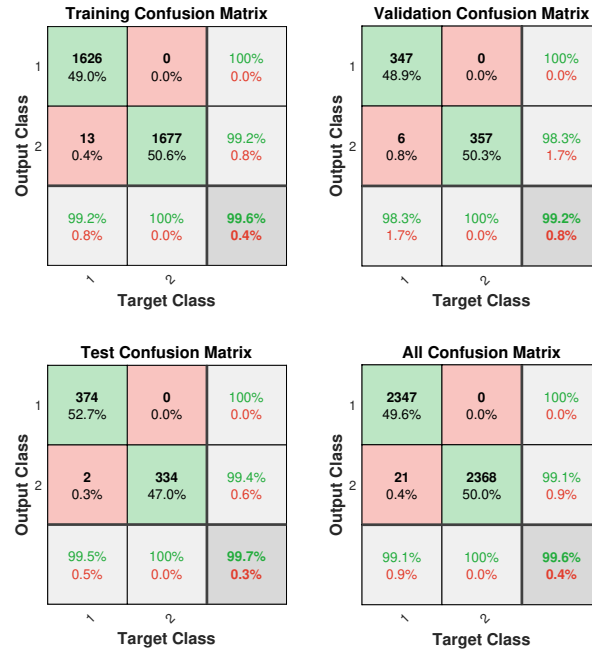


Figura 31: Matriz de confusión Ictal/Sano con RNA, utilizando la std como característica en dominio de la frecuencia.

12.5. Matrices de confusión de RNA utilizando características individuales en dominio de la frecuencia para dos clases (Interictal/Preictal)

La etiqueta 1 corresponde a la clase interictal y la etiqueta 2 a la clase preictal.

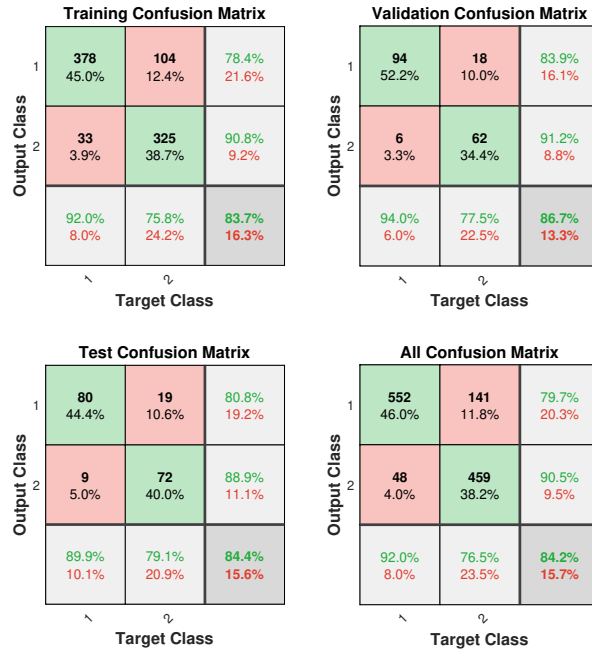


Figura 32: Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 2 como característica en dominio de la frecuencia.

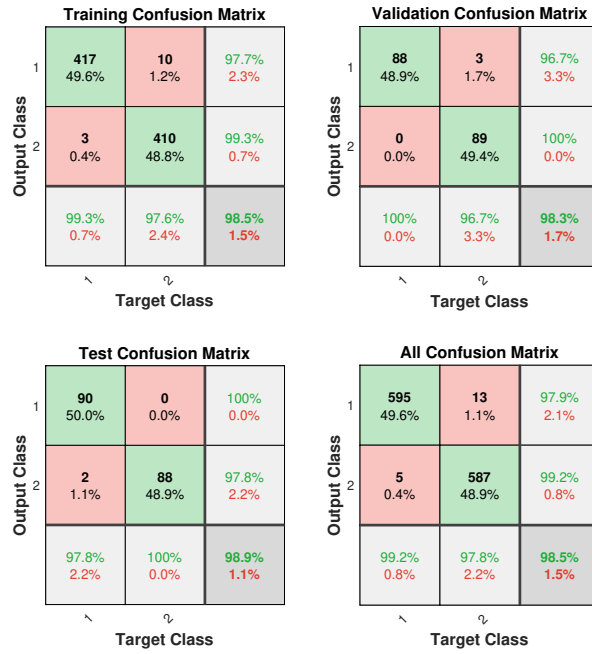


Figura 33: Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 3 como característica en dominio de la frecuencia.

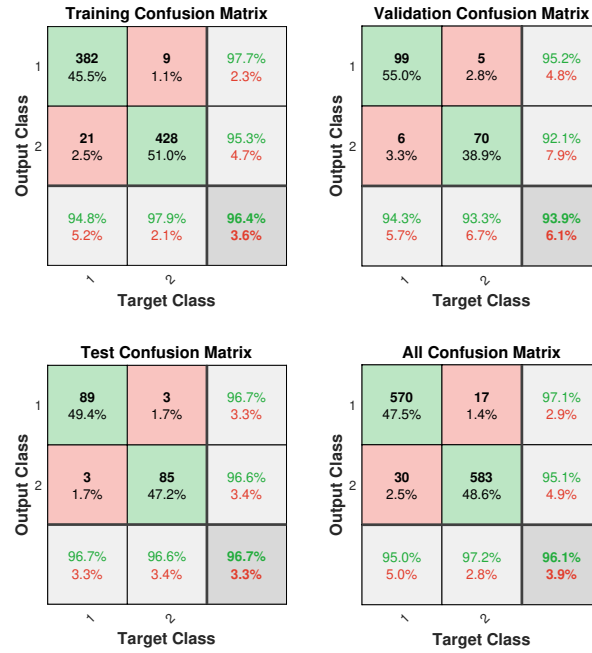


Figura 34: Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 4 como característica en dominio de la frecuencia.

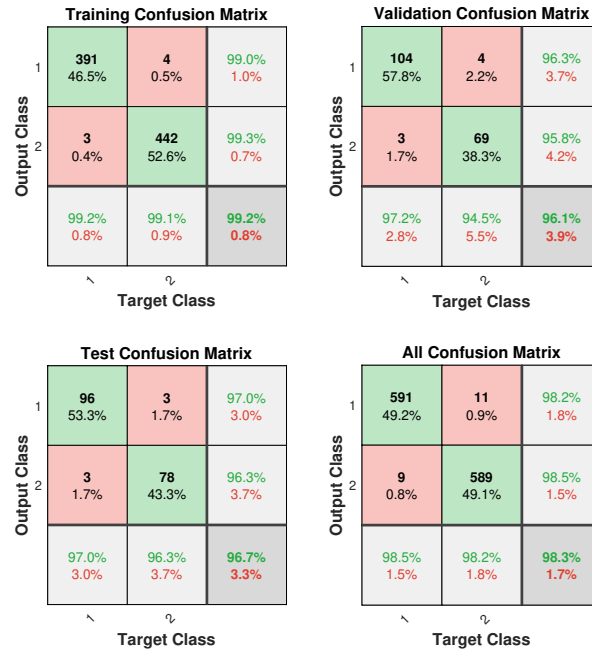


Figura 35: Matriz de confusión Interictal/Preictal con RNA, utilizando la razón 5 como característica en dominio de la frecuencia.



Figura 36: Matriz de confusión Interictal/Preictal con RNA, utilizando la std como característica en dominio de la frecuencia.

